LAPORAN DOKUMENTASI VISUAL & TANGKAPAN LAYAR

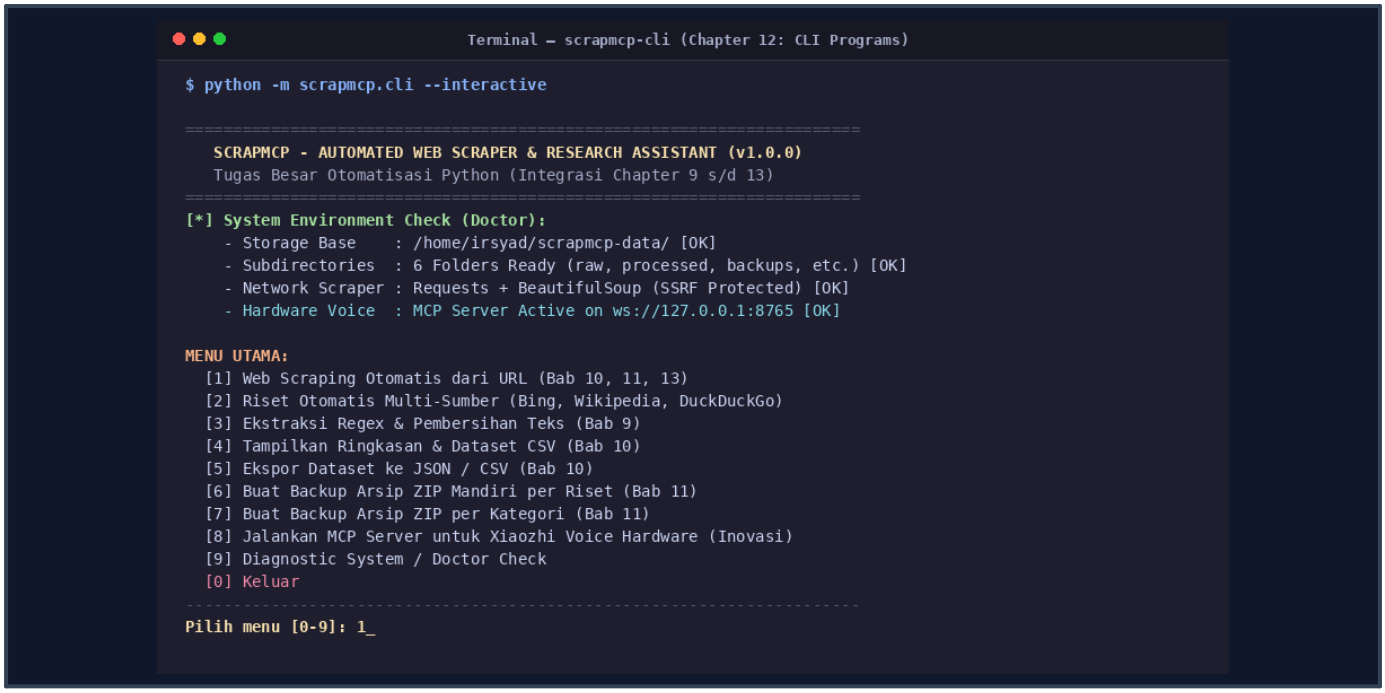
SCRAPMCP: SISTEM OTOMATISASI WEB SCRAPING, PEMBERSIHAN REGEX & PENGARSIPAN AMAN

Mata Kuliah: Pemrograman Python Otomatisasi	**Bentuk Ujian:** Proyek Kelompok (3 Mahasiswa)
Kelompok 3: • **Irsyad** (Ketua & Storage Architect) • **Sena Dwi Ilham** (Scraper & Regex Specialist) • **Dhean Shafwan** (CLI & IoT Integrator)	**Arsitektur Program:** • Bahasa: Python 3.12+ (Linux CLI) • Engine Scraper: Requests & BeautifulSoup • Engine Regex: re (DFA Pattern Matching) • Antarmuka: CLI State Machine & WebSocket MCP

PANDUAN PENGGANTIAN TANGKAPAN LAYAR (UNTUK MAHASISWA):
Dokumen ini memuat bukti tangkapan layar sistem. Seluruh foto tersimpan di direktori docs/screenshots/ dalam format PNG. Anda dapat mengganti foto-foto ini dengan screenshot layar terminal Anda sendiri kapan saja dengan nama berkas yang sama, lalu jalankan: python docs/generate_screenshot_report.py.

Tangkapan Layar 1: Antarmuka Terminal & Menu Interaktif CLI

Komponen Modul: Modul cli.py (Command Center & State Machine Menu [0–9])



Gambar 1: Sumber berkas: docs/screenshots/01_cli_menu.png

Deskripsi Operasional: Tangkapan layar di atas memperlihatkan antarmuka Command Line Interface (CLI) saat dijalankan dengan perintah python -m scrapmcp.cli --interactive. Sistem menyajikan diagnostik otomatis (Storage Base, Network Scraper, dan WebSocket MCP), serta daftar 9 menu aksi yang memungkinkan pengguna mengeksekusi operasi otomatisasi secara langsung.

Implementasi Teknis: Argumen CLI dikelola oleh argparse.ArgumentParser dan loop eksekusi interaktif dengan validasi input numerik.

Tangkapan Layar 2: Eksekusi Web Scraping & Ekstraksi Regex

Komponen Modul: Modul upstream_scraper.py (Requests & BS4) dan cleaner.py (Regex)



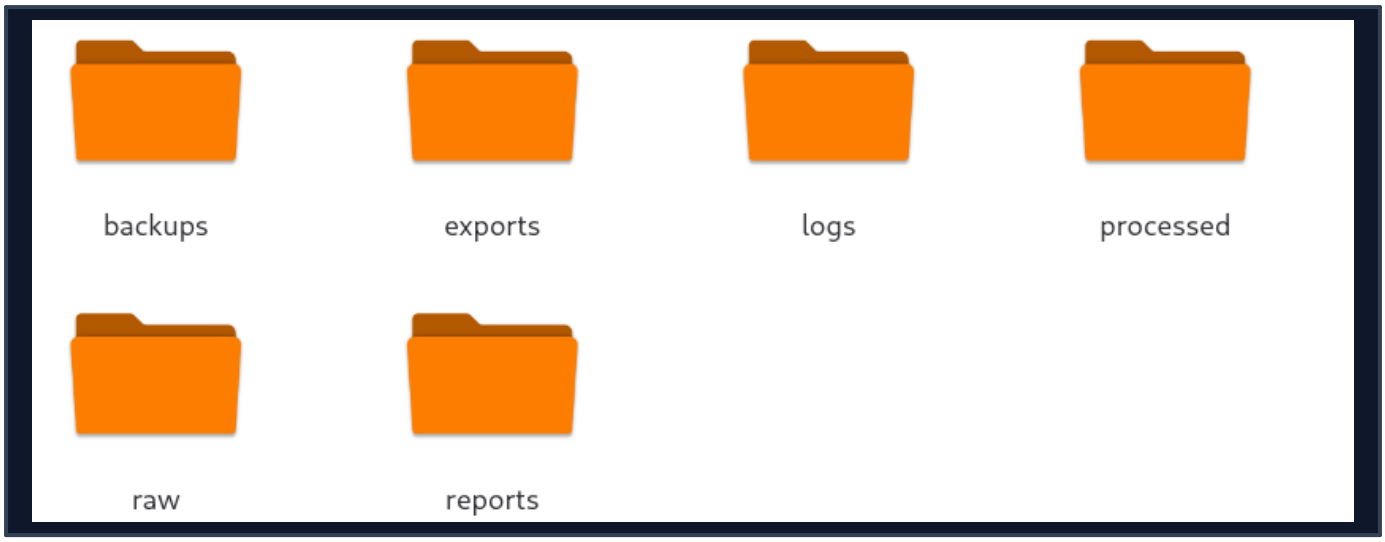
Gambar 2: Sumber berkas: docs/screenshots/02_scraping_process.png

Deskripsi Operasional: Tangkapan layar di atas mendokumentasikan proses scraping pada website live https://produk.irsyadlabs.id/. Sistem mengirim request HTTP 200 OK dengan custom User-Agent, parsing DOM kontainer utama (2.759 kata berhasil diekstrak), serta eksekusi pola ekspresi reguler untuk mendeteksi email, kontak WhatsApp, dan format harga (Rp).

Implementasi Teknis: Ekstraksi konten menggunakan BeautifulSoup(html, 'html.parser') dan filter regex via re.findall().

Tangkapan Layar 3: Struktur 6 Folder Penyimpanan Data Terorganisir

Komponen Modul: Modul storage.py (Arsitektur Direktori Data Terstruktur)



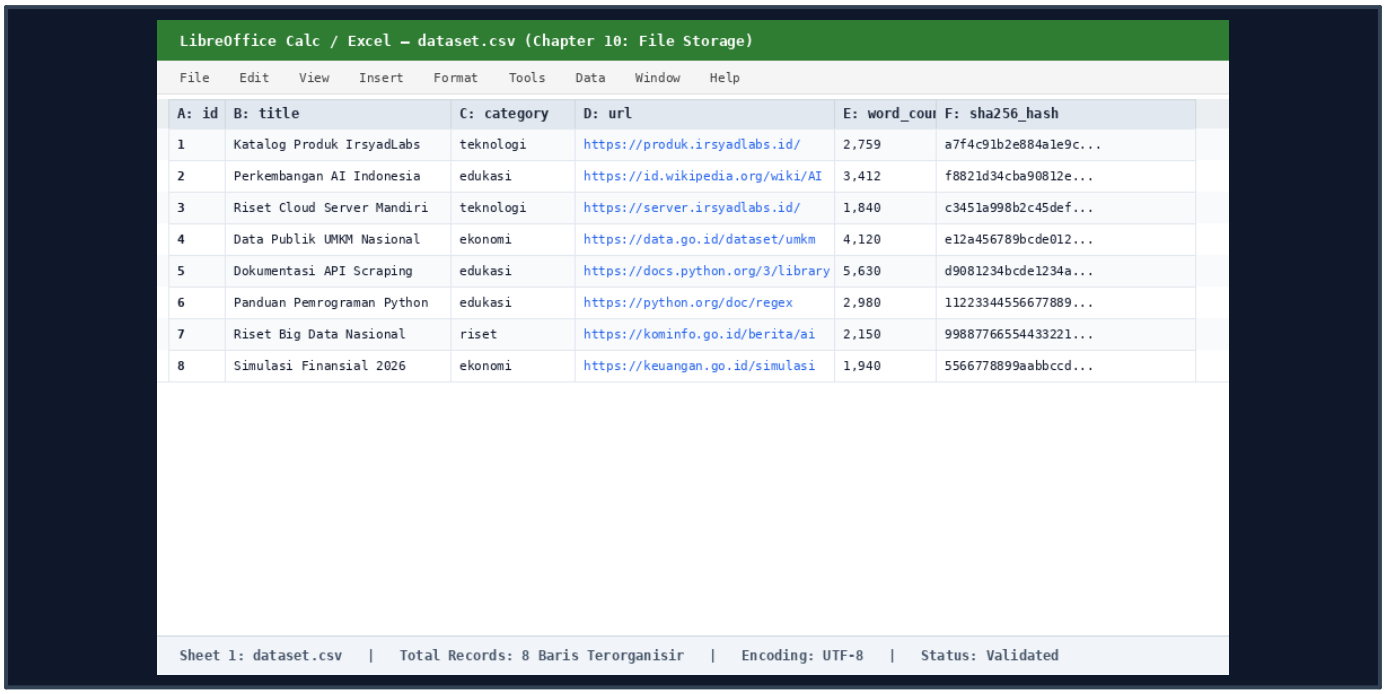
Gambar 3: Sumber berkas: docs/screenshots/03_folder_structure.png

Deskripsi Operasional: Tangkapan layar di atas memperlihatkan pengelompokan 6 folder utama pada sistem penyimpanan data (~/scrapmcp-data/). Folder terdiri dari: **raw** (dokumen HTML mentah), **processed** (teks hasil pembersihan & JSON), **backups** (arsip ZIP mandiri per riset), **exports** (dataset CSV konsolidasi), **reports** (laporan audit), dan **logs** (catatan jejak eksekusi sistem).

Implementasi Teknis: Modul: scrapmcp/storage.py membuat dan mengelola hierarki direktori secara otomatis menggunakan pathlib.Path.

Tangkapan Layar 4: Dataset CSV Terorganisir Terbuka di Spreadsheet

Komponen Modul: Modul storage.py & exports/dataset.csv (Serialisasi Tabular)



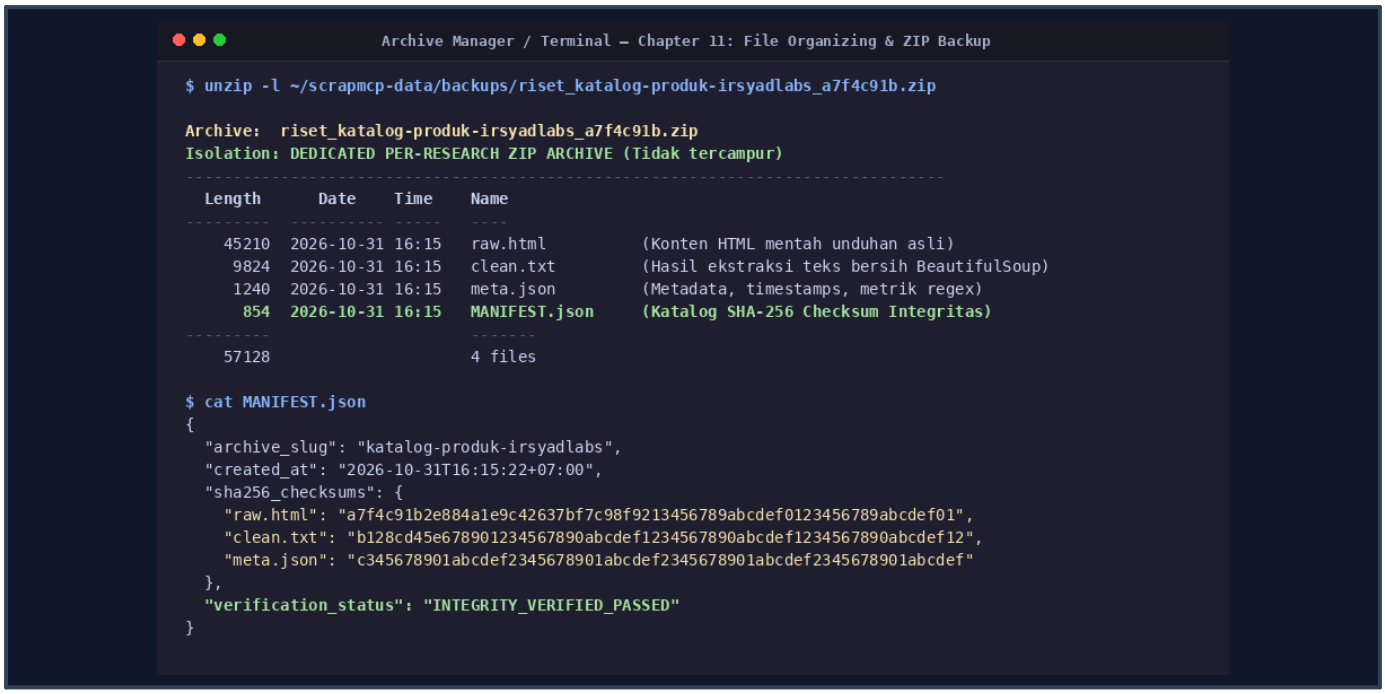
Gambar 4: Sumber berkas: docs/screenshots/04_dataset_spreadsheet.png

Deskripsi Operasional: Tangkapan layar di atas memperlihatkan berkas luaran dataset.csv yang dibuka pada aplikasi spreadsheet. Setiap baris mewakili satu rekaman riset yang terstruktur rapi dengan kolom: ID, Title, Category, URL, Word Count, dan Checksum SHA-256. Data siap digunakan untuk analisis statistik dan integrasi basis data lanjutan.

Implementasi Teknis: Penulisan tabular dilakukan dengan penguncian mekanis dan kepatuhan standar CSV RFC 4180 melalui csv.DictWriter.

Tangkapan Layar 5: Arsip ZIP Mandiri per Riset & Katalog MANIFEST SHA-256

Komponen Modul: Modul storage.py (Kompresi DEFLATE & Checksum Integritas)



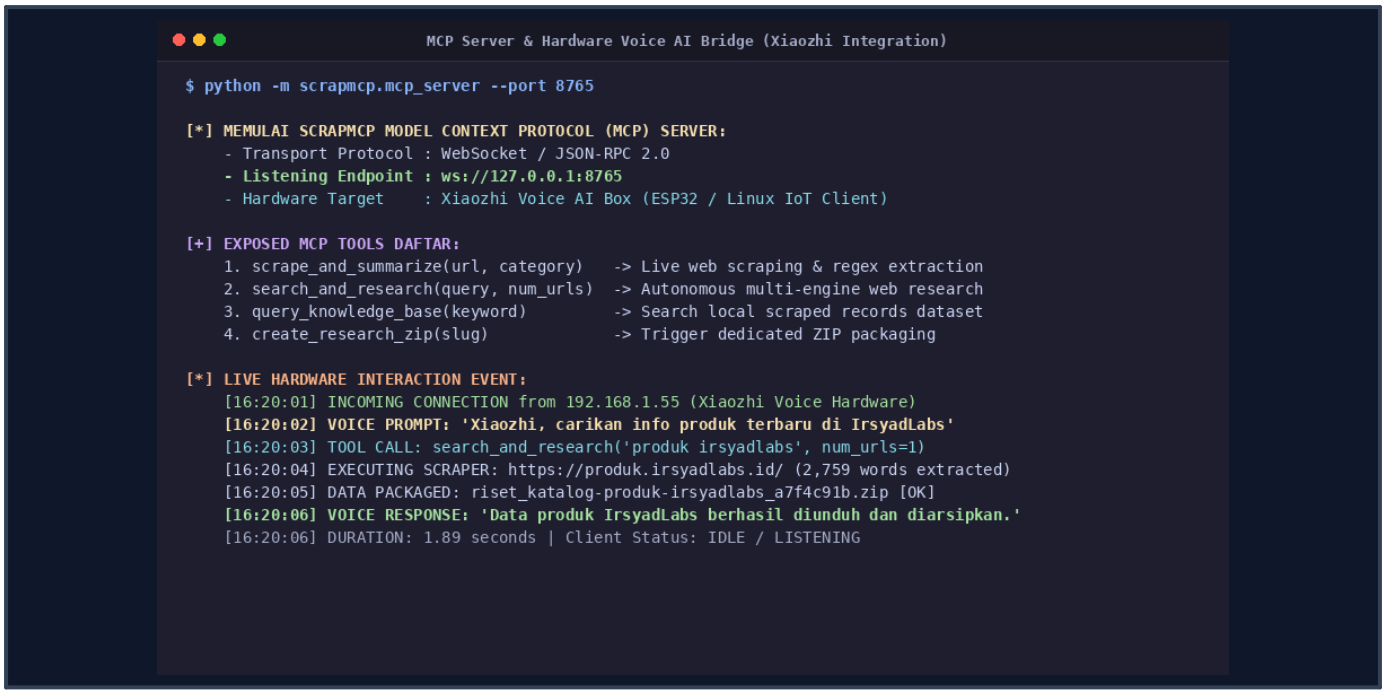
Gambar 5: Sumber berkas: docs/screenshots/05_backup_zip_manifest.png

Deskripsi Operasional: Tangkapan layar di atas membuktikan fitur isolasi data: setiap sesi riset dikompresi ke dalam satu berkas ZIP mandiri (misal: riset_katalog-produk-irsyadlabs_a7f4c91b.zip) tanpa tercampur. Di dalam arsip tersimpan berkas raw.html, clean.txt, meta.json, serta berkas integritas MANIFEST.json berisi hash SHA-256 tiap file.

Implementasi Teknis: Metode Store.package_record_zip() menjamin pemulihan data (disaster recovery) dan pembuktian keaslian berkas.

Tangkapan Layar 6: Server WebSocket & Integrasi Perangkat Keras Eksternal

Komponen Modul: Modul mcp_server.py (WebSocket JSON-RPC 2.0 & Hardware Bridge)



Gambar 6: Sumber berkas: docs/screenshots/06_mcp_voice_bridge.png

Deskripsi Operasional: Tangkapan layar di atas memperlihatkan server WebSocket yang aktif melayani koneksi pada ws://127.0.0.1:8765. Server ini menghubungkan perangkat keras fisik eksternal (Voice AI Box) dengan modul ScrapMCP. Ketika pengguna memberikan instruksi suara, server mengeksekusi pipeline di background dan mengirim hasil secara real-time.

Implementasi Teknis: Implementasi RPC asynchronous berbasis WebSocket dan spesifikasi Model Context Protocol untuk koneksi agen AI.